
机器学习课程大作业报告

题 目	基于机器学习的红酒质量预测研究
学 院	
专 业	
姓 名	
学 号	
任课教师	
成 绩	

目 录

摘 要	3
ABSTRACT	4
第一章 绪论	5
第二章 数据集与方法	6
第三章 实验设计与模型优化	8
第四章 实验结果与分析	10
第五章 结论与展望	12
附录 A 关键源代码	13
参考文献	14

摘 要

红酒质量评价通常依赖品酒师的感官评分，而理化指标能够在生产与质检环节较早获得。为探讨基于机器学习的自动预测方法，本文使用红酒质量数据集中的 1599 个样本，以 11 项理化指标为输入，以 quality 等级为输出，严格按题意将前 1300 条样本划分为训练集、后 299 条样本划分为测试集。实验在训练集内完成标准化、特征选择、主成分分析、多模型比较和 5 折分层交叉验证；比较逻辑回归、支持向量机、随机森林、极端随机树和直方图梯度提升等方法。针对类别不均衡问题，模型选择以 macro-F1 为主，并同时报告 accuracy、balanced accuracy、weighted-F1 和平均绝对误差。最终采用 SelectKBest 与 ExtraTrees 组成的流水线，在 48 组参数上进行网格搜索，最优交叉验证 macro-F1 为 0.4529。最终模型在 299 个测试样本上的 accuracy 为 0.5518、macro-F1 为 0.2776、MAE 为 0.5318。结果表明，模型对 5 级和 6 级这一主要样本区间具有较稳定的预测能力，但对数量极少的 3 级和 8 级样本识别仍受限。本文给出了从数据核验、特征工程到最终预测的可复现实验流程，并据此分析方法的适用边界。

关键词：红酒质量预测 机器学习 特征选择 极端随机树 交叉验证

ABSTRACT

This study develops a reproducible machine-learning workflow for red wine quality prediction from physicochemical measurements. The dataset contains 1,599 samples and eleven input variables. Following the assignment specification, the first 1,300 samples are used for training and the remaining 299 samples are held out for final testing. All preprocessing, feature selection, principal component analysis, model comparison, and hyperparameter search are conducted on the training set only. Logistic regression, support vector machine, random forest, ExtraTrees, and histogram gradient boosting are compared with five-fold stratified cross-validation. Because the quality classes are imbalanced, macro-F1 is used as the primary selection metric alongside accuracy, balanced accuracy, weighted-F1, and MAE. The selected SelectKBest plus ExtraTrees pipeline obtains a best cross-validation macro-F1 of 0.4529. On the held-out test set, it achieves an accuracy of 0.5518, a macro-F1 of 0.2776, and an MAE of 0.5318. The results show reasonable discrimination for the dominant quality levels while also revealing the difficulty of predicting very rare quality scores.

Key words: red wine quality prediction; machine learning; feature selection; ExtraTrees; cross-validation

第一章 绪论

1.1 研究背景与意义

红酒的风味与品质受原料、发酵、储存等多种因素影响。传统质量评价主要依赖感官评定，具有直观有效的优点，但也会受到评价成本、人员经验和主观差异的影响。酒液的酸度、挥发酸、硫化物、密度、pH、硫酸盐和酒精度等理化指标则易于在生产检测中获取。若能从这些客观指标中学习质量等级与特征之间的关系，就可以为筛查、过程监控和辅助品控提供定量参考。

本题数据来自葡萄牙绿酒的红酒子集，quality 由至少 3 位专家评分的中位数形成[1]。该任务既可以视作有序回归问题，也可以视作多分类问题。考虑到题目要求使用 predict 和 argmax 进行预测，本文将 quality 的离散等级 3 至 8 建模为六分类任务，并以类别概率最大的等级作为输出。

1.2 问题描述与研究目标

研究目标是在不改变样本顺序的前提下，使用前 1300 条记录训练模型，并对后 299 条记录进行独立测试。实验首先核验数据的维度、字段类型和缺失情况；随后使用训练集完成模型选择和超参数优化；最后仅在测试集上给出一次性预测与评价。该设置避免测试集信息进入建模过程，使最终指标能够反映模型面对未参与训练样本时的表现。

1.3 研究路线

本文遵循“数据核验—探索分析—特征处理—交叉验证—参数优化—测试评估”的路线。其中，所有会从数据学习参数的步骤均放入 Pipeline 或交叉验证折内执行，防止在训练集内部产生数据泄漏；同时保留多数类基线，以判断复杂模型是否真正优于简单的类别频率预测。

第二章 数据集与方法

2.1 数据集构成与质量核验

数据文件采用分号分隔，共 1599 条样本和 12 列字段，其中 11 列为连续型理化指标，quality 为 0 至 10 分制中的离散感官等级。本次数据实际出现的 quality 等级为 3、4、5、6、7 和 8。读取后检验未发现缺失值；数据中有 240 条重复记录，但为严格维持题目规定的 1599 条样本与固定前后切分，实验未删除或合并重复记录。

项目	实际结果	处理方式
样本总数	1599	保留全部样本
输入特征	11 项理化指标	连续数值变量
标签	quality，取值 3 至 8	六分类建模
缺失值	0	无需插补
重复记录	240	保留以符合固定切分
训练集/测试集	1300 / 299	按原始顺序切分

表 2-1 数据集核验与处理结果

2.2 标签分布与类别不平衡

质量等级分布高度集中在 5 级和 6 级：两类合计 1319 条，占全部样本的 82.49%。3 级和 8 级分别只有 10 条和 18 条。因此，单独使用 accuracy 容易掩盖少数类别的误判。本文采用分层交叉验证保持每折的类别比例，并把 macro-F1 作为超参数选择主指标，使每一个质量等级的 F1 分数都具有相同权重。




图 2-1 红酒质量等级分布

2.3 特征选择、特征提取与候选模型

特征选择使用 ANOVA F 检验，对每个理化指标与多分类标签之间的组间差异进行打分。F 分数越高，说明该指标在不同质量等级之间的均值差异越明显。训练集上的结果显示，alcohol 和 volatile acidity 最具区分度；残糖 residual sugar 的 p 值为 0.0620，在当前训练集上未达到 0.05 显著性水平。最终网格搜索选择 10 个特征，仅排除 residual sugar。

类别	特征
最终保留	fixed acidity, volatile acidity, citric acid, chlorides
最终保留	free sulfur dioxide, total sulfur dioxide, density, pH
最终保留	sulphates, alcohol
最终排除	residual sugar

表 2-2 SelectKBest 最终特征集合

作为特征提取对照，本文还对标准化后的特征进行主成分分析（PCA）。训练集上保留 95% 累计解释方差需要 9 个主成分。PCA+逻辑回归被纳入模型比较，但最终没有作为最优方案；原因是 PCA 压缩后的成分可解释性较弱，且其 macro-F1 低于树模型。

2.4 评价指标与验证方式

设测试或验证样本总数为 N ，真实标签为 y_i ，预测标签为 $\hat{y}_i$ 。accuracy 用于衡量整体正确率；macro-F1 先分别计算每个类别的 F1 后再求平均，更适合观察不均衡类别的总体识别效果；MAE 则衡量预测等级与真实等级之间的平均绝对偏差。

$$Accuracy = (1 / N) \sum I(y_i = \hat{y}_i)$$
$$F_1 = 2PR / (P + R) \quad MAE = (1 / N) \sum |y_i - \hat{y}_i|$$

交叉验证采用 5 折 StratifiedKFold，并固定 random_state 为 42。每一折都重新拟合标准化、SelectKBest 和 PCA 等变换，再在验证部分评分。这样可避免将整套训练数据的统计特征提前暴露给某个验证折。

第三章 实验设计与模型优化

3.1 实验环境与可复现设置

实验使用 Python 3.11、pandas 3.0.5 和 scikit-learn 1.9.1 完成。所有随机森林和 ExtraTrees 模型的 random_state 固定为 42，并将 n_jobs 设为 1，以避免并行环境差异影响实验记录。Notebook 保留了数据读取、图表生成、模型训练、网格搜索和测试预测的原始输出。

3.2 训练集内模型比较

候选模型包括多数类基线、逻辑回归、逻辑回归+SelectKBest、PCA+逻辑回归、RBF 核 SVC、随机森林、ExtraTrees 和直方图梯度提升。下表列出训练集 5 折交叉验证均值。基线准确率为 0.4200，说明仅预测多数类别会造成表面正确率；树模型在 accuracy、weighted-F1 和 MAE 方面具有优势，而直方图梯度提升在未调参模型中取得最高 macro-F1。

模型	Accuracy	Balanced Acc.	Macro-F1	Weighted-F1	MAE
HistGradientBoosting	0.6862	0.3753	0.3875	0.6719	0.3523
ExtraTrees	0.7092	0.3754	0.3839	0.6921	0.3254
RandomForest	0.7077	0.3708	0.3832	0.6891	0.3238
SVC (RBF)	0.5323	0.3647	0.3233	0.5487	0.5531
LogisticRegression	0.4277	0.3897	0.2827	0.4696	0.7685
Majority baseline	0.4200	0.1667	0.0986	0.2485	0.7446

表 3-1 候选模型的 5 折交叉验证结果

综合可解释性、特征选择能力和对不均衡指标的优化空间，后续选择 ExtraTrees 与 SelectKBest 的组合进行调参。这不是使用测试集做出的选择，而是基于训练集交叉验证的模型选择决策。

3.3 网格搜索与超参数选择

调参流水线由 SelectKBest 和 ExtraTreesClassifier 组成。搜索范围包括保留特征数 k、树数量、最大深度、叶节点最小样本数、最大特征比例和类别权重，共形成 48 组配置。GridSearchCV 以 macro-F1 为 refit 指标，仍使用前述 5 折分层划分。

参数	搜索候选	最终选择
select_k	8, 10, 11	10
n_estimators	200	200
max_depth	None, 16	16
min_samples_leaf	2, 4	4
max_features	sqrt, 0.8	0.8
class_weight	None, balanced	balanced

表 3-2 ExtraTrees 网格搜索范围与最优参数

最优配置的 5 折 macro-F1 为 0.4529，balanced accuracy 为 0.4874，accuracy 为 0.6600，weighted-F1 为 0.6634，交叉验证 MAE 为 0.3985。与未调参 ExtraTrees 的 macro-F1 0.3839 相比，调参后的流水线提升 0.0690，说明在类别权重、树深度和叶节点规模上进行约束有助于兼顾多数类与少数类。



图 3-1 候选模型在训练集上的交叉验证比较

第四章 实验结果与分析

4.1 特征区分度与主成分分析

ANOVA F 检验显示, alcohol 的 F 分数为 103.1595, 明显高于其他变量; volatile acidity 的 F 分数为 49.1978, total sulfur dioxide 为 23.1780。该排序表明酒精度、挥发酸和总二氧化硫在训练样本不同质量等级之间具有较强区分度。但 F 检验只刻画单变量与标签的关系, 最终模型仍需要通过树的分裂组合刻画多个指标之间的非线性关系。




图 4-1 训练集上各理化指标的 ANOVA F 分数

标准化后的 PCA 结果表明, 9 个主成分可达到 95% 的累计解释方差。PCA 有助于降低维度和缓解相关性, 但在本实验中 PCA+逻辑回归的 5 折 macro-F1 为 0.2775, 低于树模型; 因此最终模型保留原始可解释特征。




图 4-2 训练集 PCA 累计解释方差

4.2 最终测试集预测结果

确定最优参数后，使用完整的 1300 条训练数据重新拟合 Pipeline，并对 299 条测试数据调用 predict。同时调用 predict_proba 得到各等级概率，并以 argmax 选择概率最大的类别；两种方式得到的标签已在 Notebook 中通过断言核对一致。测试集在调参和模型选择过程中从未使用，因此以下结果是独立测试结果。

指标	测试集结果	解释
Accuracy	0.5518	299 条样本中整体正确率
Balanced accuracy	0.3006	各类别召回率的平均值
Macro-F1	0.2776	各类别 F1 的等权平均
Weighted-F1	0.5634	按类别样本数加权的 F1
MAE	0.5318	预测等级与真实等级的平均绝对偏差

表 4-1 最优模型在独立测试集上的评价指标

从逐类结果看，5 级的 F1 为 0.6768、6 级的 F1 为 0.5508，是模型主要有效的等级区间；7 级样本的召回率为 0.4286，但精确率为 0.2308。3 级和 8 级在测试集中分别只有 4 条和 3 条，最终未被正确识别。该现象与训练集中极端等级样本稀少相一致，也解释了 accuracy 高于 macro-F1 的原因。




图 4-3 最优模型在测试集上的混淆矩阵

第五章 结论与展望

5.1 主要结论

第一，按题目规定的固定样本顺序完成了 1300/299 训练测试划分，并将特征选择、标准化、PCA 和参数搜索严格限制在训练集内。第二，在多种候选模型中，树模型总体优于逻辑回归和多数类基线；经训练集 5 折调参后，SelectKBest+ExtraTrees 获得 0.4529 的交叉验证 macro-F1。第三，最终测试集 accuracy 为 0.5518、MAE 为 0.5318，模型对主流质量等级 5 和 6 具有一定识别能力，但无法可靠区分稀有的极端等级。

5.2 特征重要性与局限性

最终 ExtraTrees 模型的特征重要性显示，alcohol、volatile acidity 和 sulphates 位列前三。该结果与单变量 F 检验并不完全相同，说明树模型还利用了变量之间的组合关系。需要注意的是，基于不纯度的特征重要性主要用于模型解释，不等价于因果结论。




图 5-1 最终模型的特征重要性

本研究的局限主要有三点：其一，固定顺序切分可能使训练集和测试集的分布存在差异；其二，质量等级严重不均衡，导致少数类的估计方差较大；其三，理化指标不能覆盖葡萄品种、品牌、价格和储存条件等信息。后续可在保证独立测试集不泄漏的前提下，尝试有序分类、代价敏感学习、重采样或校准概率，并收集更多高低质量等级样本。

附录 A 关键源代码

以下代码为 Notebook 中的关键实现片段，完整可运行代码及其原始输出保存在 `B_red_wine_quality_prediction.ipynb` 中。

```
df = pd.read_csv(DATA_PATH, sep=';')
train_df = df.iloc[:1300].copy()
test_df = df.iloc[1300:1599].copy()
X_train, y_train = train_df[FEATURE_NAMES], train_df['quality']
X_test, y_test = test_df[FEATURE_NAMES], test_df['quality']

pipeline = Pipeline([
    ('select', SelectKBest(score_func=f_classif)),
    ('clf', ExtraTreesClassifier(random_state=42, n_jobs=1)),
])
param_grid = {
    'select__k': [8, 10, 11],
    'clf__n_estimators': [200],
    'clf__max_depth': [None, 16],
    'clf__min_samples_leaf': [2, 4],
    'clf__max_features': ['sqrt', 0.8],
    'clf__class_weight': [None, 'balanced'],
}
search = GridSearchCV(pipeline, param_grid, scoring=SCORING,
                      refit='macro_f1', cv=CV, n_jobs=1)
search.fit(X_train, y_train)
best_model = search.best_estimator_
y_pred = best_model.predict(X_test)
proba = best_model.predict_proba(X_test)
assert np.array_equal(y_pred, classes[np.argmax(proba, axis=1)])
```

代码采用 `n_jobs=1` 以保证本地执行稳定，并在最终预测阶段同时保留 `predict` 与 `predict_proba + argmax` 的一致性核验。

参考文献

- [1] Cortez P, Cerdeira A, Almeida F, Matos T, Reis J. Modeling wine preferences by data mining from physicochemical properties[J]. Decision Support Systems, 2009, 47(4): 547-553.
- [2] Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: Machine learning in Python[J]. Journal of Machine Learning Research, 2011, 12: 2825-2830.
- [3] Geurts P, Ernst D, Wehenkel L. Extremely randomized trees[J]. Machine Learning, 2006, 63(1): 3-42.
- [4] Breiman L. Random forests[J]. Machine Learning, 2001, 45(1): 5-32.
- [5] Bishop C M. Pattern Recognition and Machine Learning[M]. New York: Springer, 2006.
- [6] Scikit-learn Developers. Scikit-learn User Guide[EB/OL]. https://scikit-learn.org/stable/user_guide.html, 2026-09-15.

任课教师评语	任课教师签名：
成绩	
备注	